1. Filosofías de Clasificación Probabilística

- **Modelo Generativo (Generative Model / Naive Bayes):** Modelo probabilístico que aprende la distribución conjunta $P(X, Y) = P(X \mid Y)P(Y)$, estimando cómo se "generan" las palabras dentro de cada clase.
- **Modelo Discriminativo (Discriminative Model / Regresión Logística / Máxima Entropía):** Modelo probabilístico que se enfoca directamente en la probabilidad posterior condicional $P(Y \mid X)$, aprendiendo a "separar" óptimamente las clases mediante un hiperplano.
- **Supuesto de Independencia Condicional:** Asunción fundamental de Bayes Ingenuo que establece que la presencia de cada palabra en un documento es independiente de las demás palabras dada la clase. Al ignorar las correlaciones reales del lenguaje, NB tiende a sobreestimar las probabilidades de clase, produciendo probabilidades saturadas o "sobreconfiadas".

---

2. Representación de Texto y Vectorización

- **Bolsa de Palabras (Bag of Words - BoW / CountVectorizer):** Representación vectorial que cuenta la frecuencia absoluta de aparición de cada palabra en un documento, descartando el orden y la estructura gramatical.
- **TF-IDF (Term Frequency - Inverse Document Frequency):** Ponderación que combina la frecuencia del término (tf) con la frecuencia inversa en documentos (idf) para atenuar palabras muy frecuentes en el corpus (como *"the"* o *"and"*) y resaltar palabras raras y discriminativas.
- **TF Sublineal (**$\text{tf} = 1 + \log(\text{count})$**):** Escala logarítmica que suaviza el impacto de la frecuencia de las palabras, bajo el principio de que un término que aparece 20 veces no es 20 veces más importante que uno que aparece 1 vez.
- **IDF Suavizado (Smooth IDF):** Ajuste de $+1$ en el denominador de la fórmula de IDF ($\log\left(\frac{1+N}{1+\text{df}}\right) + 1$) para evitar divisiones entre cero y asegurar pesos bien definidos para todos los términos.
- **Ley de Zipf:** Principio empírico en NLP que establece que la frecuencia de una palabra es inversamente proporcional a su rango de frecuencia ($f \propto \frac{1}{r}$).

---

3. Técnicas de Suavizado y Regularización

- **Suavizado de Laplace (**α **/ Add-one Smoothing):** Técnica probabilística que agrega un valor constante α a todos los conteos de palabras para evitar que las palabras no vistas en entrenamiento asignen probabilidad cero a un documento completo.
- **Regularización** L_2 **(Ridge):** Penalización agregada a la función de pérdida de la Regresión Logística que suma la magnitud al cuadrado de los coeficientes ($\lambda \sum w_i^2$). Evita el sobreajuste comprimiendo los pesos de características ruidosas en espacios de alta dimensionalidad.
- **Hiperparámetro** C **(**$C = \frac{1}{\lambda}$**):** Parámetro de scikit-learn que controla el inverso de la fuerza de regularización. Un valor de C pequeño aplica una penalización fuerte, mientras que un C grande aplica una penalización débil.

---

4. Metodología Experimental e Integridad de Datos

- **Partición Estratificada (Stratified Split - Train / Dev / Test):** División del corpus en conjuntos de Entrenamiento (70%), Validación/Desarrollo (15%) y Prueba (15%), asegurando que cada subconjunto conserve exactamente la misma proporción de clases.
- **Fuga de Información (Data Leakage):** Error metodológico que ocurre cuando el modelo obtiene acceso indirecto a información de los conjuntos de validación o prueba durante la fase de entrenamiento (por ejemplo, al aprender el vocabulario o calcular TF-IDF con todo el dataset en lugar de únicamente con Train).
- **Estudio de Ablación (Ablation Study):** Experimento que aísla componentes individuales (por ejemplo, evaluar BoW vs. TF-IDF bajo exactamente la misma tokenización) para verificar qué factor específico genera las mejoras observadas.

---

5. Métricas y Evaluación de Desempeño

- **Matriz de Confusión:** Tabla de evaluación que desglosa las predicciones en Verdaderos Positivos (VP), Verdaderos Negativos (VN), Falsos Positivos (FP) y Falsos Negativos (FN).
- **Precisión:** Proporción de noticias clasificadas como falsas que realmente lo eran ($\frac{VP}{VP+FP}$).

- **Exhaustividad / Sensibilidad (Recall):** Proporción de todas las noticias falsas reales que el modelo logró detectar ($\frac{VP}{VP+FN}$).
- **F1-Score:** Media armónica entre la Precisión y la Exhaustividad ($2 \cdot \frac{\text{Precisión} \cdot \text{Exhaustividad}}{\text{Precisión} + \text{Exhaustividad}}$), óptima para evaluar la clase de interés en métricas balanceadas.
- **AUC-ROC (Area Under the ROC Curve):** Área bajo la curva que mide la capacidad global del modelo para ordenar correctamente las instancias según su probabilidad en cualquier umbral.
- **Umbral de Decisión (Decision Threshold t^*):** Punto de corte probabilístico que determina la asignación de clase (por defecto 0.5, pero optimizable si existe asimetría en los costos de error).

---

6. Experimentos de Control e Interpretabilidad

- **Log-Razón (Log-Odds Ratio $L(w)$):** Puntuación basada en la diferencia de log-probabilidades condicionales ($\log P(w \mid \text{Fake}) - \log P(w \mid \text{Real})$) que mide el grado de asociación estadística de una palabra con la clase positiva o negativa.
- **Permutación de Etiquetas (Y-Randomization):** Experimento de control que desordena las etiquetas de entrenamiento conservando el texto, comprobando si el desempeño del modelo cae al nivel del azar ($AUC \approx 0.50$) para descartar sesgos del código.
- **Marcas de Fuente / Sesgo de Dataset (Artifacts):** Elementos del texto que no representan veracidad factual sino patrones de formato o procedencia (por ejemplo, la presencia de la palabra "Reuters", URLs o encabezados de agencia)